

Übung 1 – Theorie

Querschnittsdaten mit
Observationen $i \in \{1, \dots, N\}$ [Teils gruppiert in
Gruppen $k \in \{1, \dots, K\}$]

↓
Wir wollen diese Daten verstehen
(und später Effekte schätzen und testen)

↓
Zuerst beschreiben wir die Daten
(deskriptive Statistik; wie ist Variable X
verteilt?)

↓
(i) Wo liegt das "Zentrum" dieser Variablen X
und (ii) wie stark ist die Streuung?

- (i) • Mittelwert $\bar{X} = \frac{1}{N} \sum_{i=1}^N x_i$ [$\bar{X} = \sum_{k=1}^K f_k \bar{x}_k$]
• Median (x) = "50% der Observativen sind grösser
als der Median und 50% der Observativen sind
kleiner als der Median."

$$(ii) \cdot \text{Varianz } \text{Var}(x) = \frac{1}{N} \sum_{i=1}^N (x_i - \bar{x})^2$$

= "Die durchschnittliche quadratische Abweichung vom Mittelwert \bar{X} ."

$$\cdot \text{Standardabweichung } SA(x) = \sqrt{\text{Var}(x)}$$

Statistik
Übungsaufgaben 1

Deskriptive Statistik - Klassifizierung - Kennzahlen

1. Klassifizieren Sie folgende Daten

- a) Tägliche Aktienrenditen von 100 Firmen zwischen 1995 und 2020
- b) Donald Trump Tweets während seiner Präsidentschaft
- c) Körperlänge der beobachteten Walhaie an einem spezifischen Tag in Westaustralien
- d) Wöchentlicher Fleischkonsum in kg an der UZH Mensa zwischen 1914 und 2020
- e) Einfluss von LSD auf die Netzstruktur von Spinnen

2. Betrachten Sie folgende Rohdaten

$$2, 5, 5, 4, 4, 3, 6, 7, 6, 5, 3, 4$$

- a) Erstellen Sie eine Häufigkeitstabelle.
- b) Berechnen Sie Mittelwert und Median.
- c) Wie ändert sich der Mittelwert und der Median, wenn Sie im obigen Datensatz die 7 in eine 43 verwandeln?
- d) Erklären Sie, wie die Beziehung zwischen Mittelwert und Median Informationen über die Symmetrie einer Verteilung liefert.

B.1.11.2. Calculate the variance for samples where

- a) $N = 10$, $\sum_{i=1}^N X_i^2 = 84$, and $\sum_{i=1}^N X_i = 20$.
- b) $N = 40$, $\sum_{i=1}^N X_i^2 = 380$, and $\sum_{i=1}^N X_i = 100$.

(Hint: Think about how you can rewrite the normal variance formula.)

3. Für N Beobachtungen sei \bar{x}_g der Mittelwert in Gruppe g und $f_g = \frac{N_g}{N}$ die relative Häufigkeit der Gruppe g . Zeigen Sie dass folgendes gilt:

$$\bar{x} = \sum_{g=1}^G f_g \bar{x}_g.$$

4. Warum ist die mittlere Sterbeziffer für Krebs zwischen 1970 und 1999 angestiegen?

Alter	1970		1999	
	Anteil	Sterbeziffer	Anteil	Sterbeziffer
1-14	0.24	7	0.18	2
15-44	0.46	22	0.43	15
45-64	0.20	329	0.25	229
65-84	0.09	1395	0.12	1255
85+	0.01	2830	0.02	3002
Gesamt		231.45		274.7

5. Berechnen Sie die Standardabweichung für die Daten in Aufgabe 4 (jeweils für 1970 und 1999).

1. Klassifizieren Sie folgende Daten

- a) Tägliche Aktienrenditen von 100 Firmen zwischen 1995 und 2020
- b) Donald Trump Tweets während seiner Präsidentschaft
- c) Körperlänge der beobachteten Walhaie an einem spezifischen Tag in Westaustralien
- d) Wöchentlicher Fleischkonsum in kg an der UZH Mensa zwischen 1914 und 2020
- e) Einfluss von LSD auf die Netzstruktur von Spinnen

Einschub: Struktur der Daten

Querschnittsdaten
(zu einem Zeitpunkt)

Körpergrösse Ausbildung

Ind. 1	1.80	Bachelor
Ind. 2	1.60	Master
:	:	:
Ind. N	1.75	Lehre

~~~~~  
N Observationen

**Paneldaten**

(zu mehreren Zeitpunkten)

Körpergrösse      Ausbildung

|                          |      |          |
|--------------------------|------|----------|
| Ind. 1<br>zu Zeitpunkt 1 | 1.80 | Bachelor |
| Ind. 2, t=1              | 1.60 | Master   |
| :                        | :    | :        |
| Ind. N, t=1              | 1.75 | Lehre    |

Ind. 1, t=T

Ind. N, t=T

~~~~~  
N x T Observationen

Zeitreihen

Körpergrösse

Ind. 1

t = 1 1.80
t = 2 1.81

t > T 1.85

~~~~~  
T Observationen

## Struktur, Verfügbarkeit, Skala, Herkunft

- (a) Paneldaten, meistens öffentlich, metrisch stetig, hergeleitet aus Preisdaten
- (b) Zeitreihe, öffentlich, Textdaten, Primärdaten
- (c) Querschnittsdaten, können öffentlich sein, metrisch stetig, Primärdaten
- (d) Zeitreihe, nicht öffentlich, metrisch stetig, administrative Daten
- (e) Experiment

2. Betrachten Sie folgende Rohdaten

2, 5, 5, 4, 4, 3, 6, 7, 6, 5, 3, 4

- Erstellen Sie eine Häufigkeitstabelle.
- Berechnen Sie Mittelwert und Median.
- Wie ändert sich der Mittelwert und der Median, wenn Sie im obigen Datensatz die 7 in eine 43 verwandeln?
- Erklären Sie, wie die Beziehung zwischen Mittelwert und Median Informationen über die Symmetrie einer Verteilung liefert.

| $x_k$ | $f_k$ |
|-------|-------|
| 2     | 1     |
| 3     | 2     |
| 4     | 3     |
| 5     | 3     |
| 6     | 2     |
| 7     | 1     |

 $b) \bar{x} = \frac{1}{12} \sum_{i=1}^{12} x_i$   
 $= \frac{1}{12} (2 + 3 + 3 + \dots + 7)$   
 $= \underline{\underline{4.5}}$

Median  $\text{Med}(x)$

(i) Sortiere  $\{x_i\}_{i=1}^N$  von klein nach gross

(ii) Berechne den Median als

$$\text{Med}(x) = \begin{cases} x_{(N+1)/2}, & \text{falls } N \text{ ungerade} \\ \frac{x_{(N/2)} + x_{(N/2)+1}}{2}, & \text{falls } N \text{ gerade} \end{cases}$$

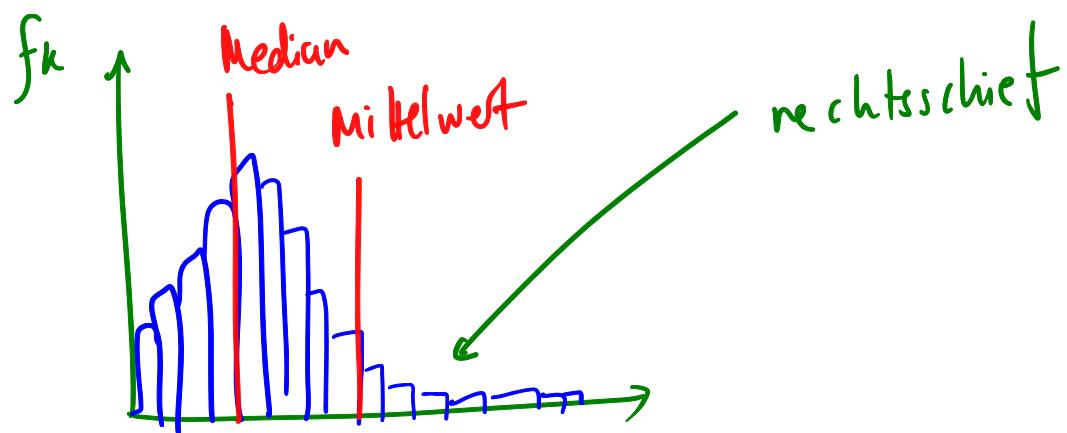
$\{2, 3, 3, 4, 4, 4, 5, 5, 5, 6, 6, 7\}$

$$\rightarrow \text{also: } \text{Med}(X) = \frac{4+5}{2} = \underline{\underline{4.5}}$$

(c) Mittelwert  $\bar{X}_{\text{NEU}} = \underline{\underline{7.5}}$

Median unverändert

(d) Mittelwert + Median einer symmetrischen Verteilung sind gleich.



B.1.11.2. Calculate the variance for samples where

a)  $N = 10$ ,  $\sum_{i=1}^N X_i^2 = 84$ , and  $\sum_{i=1}^N X_i = 20$ .

b)  $N = 40$ ,  $\sum_{i=1}^N X_i^2 = 380$ , and  $\sum_{i=1}^N X_i = 100$ .

(Hint: Think about how you can rewrite the normal variance formula.)

$$\begin{aligned}
 \text{Var}(X) &= \frac{1}{N} \sum_{i=1}^N (X_i - \bar{X})^2 \\
 &= \frac{1}{N} \sum_{i=1}^N X_i^2 - 2\bar{X}\sum_{i=1}^N X_i + \bar{X}^2 \\
 &= \frac{1}{N} \left( \sum_{i=1}^N X_i^2 - 2\bar{X} \underbrace{\sum_{i=1}^N X_i}_{N\bar{X}} + \sum_{i=1}^N \bar{X}^2 \right) \\
 &\quad = N\bar{X} = N \cdot \frac{1}{N} \sum_{i=1}^N X_i \\
 &= \frac{1}{N} \left( \sum_{i=1}^N X_i^2 - \underbrace{2\bar{X}^2 + N\bar{X}^2}_{-N\bar{X}^2} \right) \\
 \text{Var}(X) &= \frac{1}{N} \sum_{i=1}^N X_i^2 - \bar{X}^2 \\
 &\quad \uparrow \\
 &\quad \left( \frac{1}{N} \sum_{i=1}^N X_i \right)^2
 \end{aligned}$$

$$a) \text{Var}(X) = \frac{1}{10} \cdot 84 - \left( \frac{1}{10} \cdot 20 \right)^2 = \underline{\underline{4.4}}$$

$$b) \text{Var}(X) = \frac{1}{40} \cdot 380 - \left( \frac{1}{40} \cdot 100 \right)^2 = \underline{\underline{3.25}}$$

3. Für  $N$  Beobachtungen sei  $\bar{x}_g$  der Mittelwert in Gruppe  $g$  und  $f_g = \frac{N_g}{N}$  die relative Häufigkeit der Gruppe  $g$ . Zeigen Sie dass folgendes gilt:

$$\bar{x} = \sum_{g=1}^G f_g \bar{x}_g = \sum_{g=1}^G \frac{\frac{N_g}{N}}{\frac{1}{N_g}} \sum_{i=1}^{N_g} x_i$$

$$= \frac{1}{N} \sum_{g=1}^G \sum_{i=1}^{N_g} x_i$$

alle Observatoren

4. Warum ist die mittlere Sterbeziffer für Krebs zwischen 1970 und 1999 angestiegen?

| Alter  | Anteil | 1970         | $\bar{x}_g$ | 1999         |
|--------|--------|--------------|-------------|--------------|
|        |        | Sterbeziffer |             | Sterbeziffer |
| 1-14   | 0.24   | 7            |             | 0.18         |
| 15-44  | 0.46   | 22           |             | 0.43         |
| 45-64  | 0.20   | 329          |             | 0.25         |
| 65-84  | 0.09   | 1395         |             | 0.12         |
| 85+    | 0.01   | 2830         |             | 0.02         |
| Gesamt |        | 231.45       |             | 274.7        |

$$\bar{x}$$

$$\bar{x} = \sum_{j=1}^6 f_g \bar{x}_g = (0.24 \cdot 7 + 0.46 \cdot 22 + \dots + 0.01 \cdot 2830) = 231.45$$

5. Berechnen Sie die Standardabweichung für die Daten in Aufgabe 4 (jeweils für 1970 und 1999).

$$SA(x) = \sqrt{Var(x)}$$

$$SA(x) = \sqrt{\sum_{g=1}^G f_g (\bar{x}_g - \bar{x})^2}$$

$$1970: SA(x) = \sqrt{0.24 (7 - 231.45)^2 + \dots + 0.01 (2830 - 231.45)^2} \\ = \underline{\underline{472.81}}$$

$$1999: SA(x) = \underline{\underline{554.07}}$$